INFORME TÉCNICO - PROYECTO FINAL BIG DATA + POWER BI

1. RESUMEN EJECUTIVO

Este proyecto desarrolla un pipeline ETL end-to-end para la empresa ficticia TechZone usando Scala, Apache Spark 4.1.1 y una arquitectura Medallion con capas Bronze, Silver y Gold, cuyo objetivo final es producir KPIs listos para visualización en Power BI. El pipeline procesa datos sintéticos de un e-commerce entre 2023 y 2024, incluyendo ventas, productos y clientes, con más de 100.000 transacciones y problemas de calidad de datos introducidos deliberadamente para simular un caso realista de Big Data.

La solución resuelve un problema claro de negocio: TechZone no disponía de visibilidad suficiente sobre qué productos y categorías eran más rentables, cómo evolucionaban las ventas a lo largo del tiempo ni qué países concentraban más ingresos y clientes activos. Para responder a estas necesidades, el proyecto transforma datos crudos en información analítica estructurada y exporta resultados en CSV para su explotación en Power BI.

Tres hallazgos clave destacan en los resultados del proyecto. En primer lugar, el pipeline procesa ingresos totales de 264,9 millones de dólares con un margen bruto total del 6,4%. En segundo lugar, la categoría "Sin Categoría" aparece como la de mayor margen porcentual, con 12,86%, lo que evidencia el impacto analítico de la imputación y la necesidad de mejorar la calidad maestra del catálogo. En tercer lugar, Perú, Argentina y Colombia lideran los ingresos, mientras Chile presenta el mejor margen porcentual entre los países destacados.

2. DESCRIPCIÓN DEL DOMINIO

La empresa ficticia del proyecto es TechZone, un e-commerce de electrónica que opera en diez países de habla hispana y América del Norte, con 1.000 productos activos, 10.000 clientes registrados y alrededor de 100.000 transacciones anuales. Este contexto permite modelar un escenario de analítica comercial con suficiente volumen, diversidad geográfica y variedad de productos para justificar una arquitectura de procesamiento por capas.

La problemática de negocio se centra en la falta de visibilidad operativa y analítica. Antes del pipeline, la organización no sabía con claridad qué productos generaban más ingreso, qué categorías aportaban mayor margen, cómo evolucionaban las ventas mes a mes ni en qué países debía concentrar inversión comercial. Esta ausencia de información dificultaba la toma de decisiones estratégicas y la priorización de acciones comerciales.

Las preguntas de negocio definidas en el proyecto estructuran correctamente el propósito del trabajo:

- ¿Cuáles son los 10 productos con mayor ingreso total?
- ¿Cuál es el margen bruto por categoría de producto?

- ¿Cómo evolucionan las ventas mes a mes y si existe estacionalidad?
- ¿Qué países generan más ingresos y clientes activos?
- ¿Cuál es el ticket medio por país y categoría?

Estas preguntas justifican la construcción de una capa Gold orientada a negocio, donde cada tabla responde a una necesidad analítica concreta y reutilizable para reporting ejecutivo.

3. ARQUITECTURA DEL PIPELINE

La arquitectura sigue el patrón Medallion, organizado en tres capas de transformación secuenciales, desde la ingesta raw hasta la generación de KPIs. El flujo completo es: fuentes de datos en CSV, JSON y Parquet; ingesta en Bronze; limpieza y estandarización en Silver; agregación analítica en Gold; y exportación de resultados a CSV para Power BI.

```
Fuentes de datos -> Bronze -> Silver -> Gold -> Power BI
```

La capa Bronze, implementada en `01_bronze.scala`, realiza la ingesta sin transformación, preservando el dato original y añadiendo metadatos como `ingestion_timestamp` y `source_file`. La capa Silver, en `02_silver.scala`, limpia duplicados, corrige tipos, normaliza fechas, filtra precios inválidos e imputa valores nulos para hacer el dato analíticamente consistente. La capa Gold, en `03_gold.scala`, genera tablas agregadas como `top_products`, `category_kpis`, `monthly_kpis` y `country_kpis`, y además las exporta a `dashboard/` para alimentar visualizaciones en Power BI.

A nivel de organización de código, el repositorio separa claramente los módulos de generación de datos, Bronze, Silver y Gold dentro de `src/main/scala/com/example/`, lo que mejora la mantenibilidad y la lectura del proyecto. Esta estructura encaja bien con un proyecto académico o técnico orientado a demostrar buenas prácticas de organización de pipelines.

4. DESCRIPCIÓN DE FUENTES

El proyecto trabaja con tres fuentes de datos generadas sintéticamente mediante `DataGeneratorWithQualityIssues.scala`, una decisión útil para controlar tanto el volumen como los defectos de calidad que el pipeline debe resolver. Las fuentes incluyen ventas en CSV, productos en JSON y clientes en Parquet, cubriendo formatos heterogéneos frecuentes en entornos de datos reales.

Fuente	Formato	Volumen	Problemas detectados
`data/sales`	CSV	100.100 filas	5% nulos en `quantity`, 3% precios inválidos, 50% fechas en DD/MM/YYYY, 100 duplicados
`data/products`	JSON	1.000 filas	20% sin categoría, 10% espacios extra en nombre, 70% fechas en DD/MM/YYYY
`data/customers`	Parquet	10.000 filas	Datos limpios

La fuente más problemática es `sales`, ya que combina incidencias de completitud, validez, estandarización temporal y duplicidad. Por su parte, `products` introduce defectos maestros relevantes para el análisis por categoría, mientras `customers` sirve como referencia limpia para cruces posteriores.

5. DECISIONES DE LIMPIEZA

La capa Silver concentra las decisiones de calidad de datos más importantes del proyecto. Según el repositorio, se eliminaron 99 duplicados, se filtraron 3.853 precios inválidos, se imputaron 4.753 nulos en `quantity` con el valor 1 y se imputaron 200 categorías nulas con la etiqueta "Sin Categoría". También se normalizaron fechas al formato YYYY-MM-DD y se corrigieron tipos de datos para asegurar consistencia analítica.

Estas decisiones muestran un criterio técnico razonable entre eliminar e imputar. Los duplicados se eliminan porque no aportan valor analítico y distorsionan agregados. Los precios inválidos, como valores negativos o textos como "no aplica", se excluyen porque no existe una imputación fiable para una variable monetaria crítica en el cálculo de ingresos.

Los nulos en `quantity` se imputan con 1 para conservar la transacción bajo la hipótesis de venta mínima posible, lo que permite mantener mayor volumen de información sin introducir un sesgo extremo. En el caso de categorías nulas, la imputación como "Sin Categoría" preserva los productos para análisis de ingresos y costes, aunque al mismo tiempo visibiliza una debilidad de calidad en el catálogo maestro.

Problema	Estrategia aplicada	Motivo técnico
Duplicados en ventas	`dropDuplicates`	Evitar doble conteo de ingresos y volumen
Precios inválidos	Eliminar filas	No existe imputación fiable para precio de venta
Nulos en `quantity`	Imputar con `1`	Conserva la venta con valor mínimo plausible
Fechas no estandarizadas	Normalizar a ISO	Permite análisis temporal consistente
Espacios extra en nombres	`trim()`	Evita duplicados lógicos en agrupaciones
Categorías nulas	Imputar "Sin Categoría"	Mantiene cobertura analítica del catálogo

Desde una perspectiva técnica, esta fase es especialmente sólida porque conecta cada regla de limpieza con un impacto directo en la calidad del KPI final. No se trata solo de limpiar por limpiar, sino de asegurar que los agregados Gold sean interpretables y defendibles ante usuarios de negocio.

6. CATÁLOGO DE KPIs

La capa Gold genera cuatro tablas principales: `top_products`, `category_kpis`, `monthly_kpis` y `country_kpis`, cada una orientada a responder una pregunta de negocio concreta. A nivel global, el proyecto documenta ingresos totales de 264,9 millones de dólares, margen bruto total de 16,9 millones, margen bruto porcentual de 6,4% y ticket medio aproximado de 2.760 dólares.

KPI	Definición	Fórmula orientativa	Valor	Interpretación
Ingresos totales	Suma del importe de ventas procesadas	`SUM(quantity * price)`	$264.9M	Mide el volumen económico total del pipeline
Margen bruto total	Beneficio bruto total estimado	`SUM(revenue - cost)`	$16.9M	Resume la rentabilidad absoluta del negocio
Margen bruto %	Rentabilidad relativa sobre ingresos	`(gross_margin / revenue) * 100`	6.4%	Permite comparar eficiencia económica
Ticket medio	Ingreso promedio por transacción	`revenue / transactions`	~$2.760	Indica valor medio de compra
Top producto	Producto con mayor ingreso	`ORDER BY revenue DESC`	Tabla `top_products`	Identifica productos tractores del negocio
Margen por categoría	Rentabilidad por grupo de productos	`(revenue - cost) / revenue` por categoría	"Sin Categoría": 12.86%	Señala categorías más rentables o problemáticas
Evolución mensual	Tendencia temporal de ventas	`SUM(revenue)` por mes	Tabla `monthly_kpis`	Sirve para detectar estacionalidad
Rendimiento por país	Ingresos y clientes por geografía	Agregados por país	Perú: $27.9M; Chile mejor margen	Guía priorización comercial internacional

Este catálogo de KPIs demuestra que la capa Gold no se limita a consolidar datos, sino que convierte el pipeline en una herramienta de soporte a decisiones. También deja preparado el terreno para visualizaciones ejecutivas claras y reutilizables en Power BI.

7. CAPTURAS DEL DASHBOARD

La carpeta `dashboard/` contiene cuatro salidas CSV destinadas a alimentar un dashboard ejecutivo en Power BI: `top_products`, `category_kpis`, `monthly_kpis` y `country_kpis`. Aunque no se incluyen imágenes del dashboard en la información disponible, sí es posible describir con precisión las visualizaciones que deberían construirse a partir de esas tablas.

La primera visualización recomendada es una tarjeta de ingresos totales, usando el valor global de 264,9 millones de dólares, ya que resume la magnitud económica del periodo analizado y funciona como KPI principal del panel. La segunda es un gráfico de líneas con `monthly_kpis` para mostrar evolución temporal y facilitar la detección de estacionalidad o cambios de tendencia en las ventas.

La tercera visualización debería ser un gráfico de barras por categoría, construido a partir de `category_kpis`, para comparar ingresos y margen porcentual entre familias de productos. La cuarta puede ser una tabla o matriz por país usando `country_kpis`, destacando ingresos,

clientes activos, ticket medio o margen, con especial atención a Perú, Argentina, Colombia y Chile como países de referencia en resultados.

Una narrativa técnica adecuada para el informe puede describir estas capturas así:

- **Captura 1: Tarjeta de ingresos.** El dashboard presenta ingresos totales de 264,9 millones de dólares como indicador principal de salud comercial.
- **Captura 2: Gráfico de líneas mensual.** La evolución temporal permite analizar tendencias, posibles picos de demanda y variaciones estacionales apoyadas por `monthly_kpis`.
- **Captura 3: Gráfico de barras por categoría.** La comparación entre categorías revela diferencias claras en margen, destacando "Sin Categoría" con 12,86% y otras familias con márgenes inferiores.
- **Captura 4: Tabla por país.** El detalle geográfico muestra que Perú lidera ingresos con 27,9 millones, mientras Chile destaca por el mejor margen porcentual entre los países principales.

8. CONCLUSIONES

El proyecto demuestra de forma clara cómo una arquitectura Medallion aplicada con Scala y Spark puede transformar datos heterogéneos y defectuosos en KPIs fiables para analítica de negocio. También evidencia la importancia de diseñar reglas de limpieza alineadas con el impacto que tendrán sobre métricas agregadas y visualizaciones ejecutivas.

Desde el punto de vista de aprendizaje técnico, el repositorio integra varias competencias relevantes: generación sintética de datos, tratamiento de calidad, modelado por capas, exportación para consumo analítico y organización clara del código fuente. Además, muestra una separación correcta entre datos crudos, datos refinados y datos de negocio, una práctica fundamental en ecosistemas modernos de ingeniería de datos.

Como próximos pasos, el proyecto podría ampliarse con varias mejoras. Una línea natural sería incorporar predicción de demanda o segmentación de clientes mediante modelos de machine learning sobre la capa Silver o Gold. Otra mejora relevante sería evolucionar desde procesamiento batch hacia streaming o micro-batch para obtener KPIs casi en tiempo real. También tendría sentido añadir validaciones automáticas de calidad de datos, pruebas de pipeline y una integración continua que garantice reproducibilidad del proceso analítico.