Informe Técnico TechZone

Informe Técnico: Pipeline ETL Big Data — TechZone

Autor: Serio120
Fecha: Mayo 2026
Tecnologías: Scala 2.13 · Apache Spark 4.1.1 · Arquitectura Medallion

---

1. Introducción

Este informe documenta el diseño, implementación y resultados de un pipeline ETL end-to-end construido con **Scala y Apache Spark 4.1.1** sobre arquitectura **Medallion (Bronze → Silver → Gold)**.

El caso de uso es **TechZone**, un e-commerce de electrónica que opera en 10 países de habla hispana y América del Norte. La empresa necesitaba responder cinco preguntas de negocio clave a partir de datos dispersos, incompletos y con problemas de calidad.

1.1 Objetivos del proyecto

- Diseñar un pipeline ETL escalable con separación clara de responsabilidades por capa
- Generar datos sintéticos realistas con problemas de calidad documentados
- Aplicar técnicas de limpieza y normalización justificadas
- Producir KPIs ejecutivos listos para visualización en Power BI

1.2 Preguntas de negocio

#	Pregunta	Tabla Gold
Q1	¿Cuáles son los 10 productos con mayor ingreso total?	`top_products`
Q2	¿Cuál es el margen bruto por categoría de producto?	`category_kpis`
Q3	¿Cómo evolucionan las ventas mes a mes?	`monthly_kpis`
Q4	¿Qué países generan más ingresos y clientes activos?	`country_kpis`
Q5	¿Cuál es el ticket medio por país y categoría?	`category_kpis` + `country_kpis`

---

2. Arquitectura del pipeline

El pipeline sigue la arquitectura **Medallion** de tres capas, donde cada capa añade valor progresivo a los datos:

```
FUENTES RAW  →  BRONZE  →  SILVER  →  GOLD  →  POWER BI
(CSV/JSON/     (Ingesta    (Limpieza  (KPIs y   (Dashboard
 Parquet)       raw)        y tipos)   agrega.)   ejecutivo)
```

2.1 Entorno tecnológico

Componente	Versión
Scala	2.13.13
Apache Spark	4.1.1
Java	17.0.18
sbt	1.12.8
Sistema operativo	Windows 11
Formato de almacenamiento	Parquet

> **Nota sobre Delta Lake:** Delta Lake no dispone de versión compatible con Spark 4.x en el momento de desarrollo de este proyecto. Se utilizó Parquet como formato de almacenamiento, manteniendo íntegramente la arquitectura medallion y sus principios de separación por capas.

---

3. Generación de datos sintéticos

Se implementó `DataGeneratorWithQualityIssues.scala` para generar tres conjuntos de datos con problemas de calidad intencionados, simulando condiciones reales de un sistema de producción.

3.1 Conjuntos de datos generados

Fuente	Formato	Registros	Problemas introducidos
`data/sales`	CSV	100.100	Nulos, precios inválidos, fechas mixtas, duplicados
`data/products`	JSON	1.000	Categorías nulas, espacios extra, fechas mixtas
`data/customers`	Parquet	10.000	Sin problemas (datos de referencia)

3.2 Problemas de calidad introducidos

En sales (órdenes):

- **5% de nulos** en el campo `quantity` — simulando fallos de captura en TPV
- **3% de precios inválidos** — valores “no aplica” y precios negativos
- **50% de fechas en formato DD/MM/YYYY** — inconsistencia de sistema legado
- **100 registros duplicados** exactos — simulando reenvíos de mensajería

En products:

- **20% sin categoría** (`null`) — productos dados de alta sin clasificar
- **10% con espacios extra** en el nombre — error de formulario web
- **70% de fechas en formato DD/MM/YYYY** — mismo problema de sistema legado

---

4. Capa Bronze — Ingesta Raw

Clase: `com.example.bronze.BronzeIngestion`
Entrada: `data/` (CSV, JSON, Parquet)
Salida: `delta/bronze/` (Parquet)

4.1 Principios de diseño

La capa Bronze aplica el principio de **inmutabilidad** — los datos se ingieren exactamente como llegan de la fuente, sin ninguna corrección. Esto permite:

- Reproducibilidad total del pipeline
- Auditoría de datos originales
- Diagnóstico de problemas en origen

4.2 Decisiones técnicas

Decisión	Justificación
`inferSchema=false` en CSV	Preserva "no aplica" y negativos como String, sin corrección silenciosa
`mode=PERMISSIVE`	No falla ante filas malformadas
Todo como String en sales	Bronze no interpreta, solo almacena

4.3 Columnas de auditoría añadidas

Todas las tablas Bronze incluyen:

- `ingestion_timestamp` — marca temporal de ingesta
- `source_file` — identificador del sistema origen

4.4 Resultados

Tabla	Filas ingeridas
`bronze/sales`	100.100
`bronze/products`	1.000
`bronze/customers`	10.000

---

5. Capa Silver — Limpieza y Normalización

Clase: `com.example.silver.SilverCleaning`
Entrada: `delta/bronze/` (Parquet)
Salida: `delta/silver/` (Parquet)

5.1 Estrategia de limpieza

Cada problema de calidad fue tratado con una estrategia específica y justificada:

Problema	Registros afectados	Estrategia	Justificación
Duplicados exactos	99	`dropDuplicates`	Sin valor analítico
Precios inválidos	3.853	Eliminar fila	No se puede imputar un precio de venta
Nulos en `quantity`	4.753	Imputar con `1`	Venta mínima posible, conserva el registro
Fechas DD/MM/YYYY	~50.000	Normalizar a YYYY-MM-DD	Estándar ISO 8601
Espacios en nombres	~100	`trim()`	Evita duplicados lógicos en agrupaciones
Categorías nulas	200	Imputar "Sin Categoría"	Conserva el producto para análisis

5.2 Transformación de tipos

Tras la limpieza se aplicó casting de tipos estricto:

- `order_id`, `customer_id`, `product_id` → `Integer`
- `quantity` → `Integer`
- `price`, `cost` → `Double`
- `order_date`, `signup_date`, `created_date` → `Date`

5.3 Resultados

Tabla	Entrada (Bronze)	Salida (Silver)	Filas eliminadas
`silver/sales`	100.100	96.148	3.952 (3.95%)
`silver/products`	1.000	1.000	0
`silver/customers`	10.000	10.000	0

---

6. Capa Gold — KPIs y Agregaciones

Clase: `com.example.gold.GoldKPIs`
Entrada: `delta/silver/` (Parquet)
Salida: `delta/gold/` (Parquet) + `dashboard/` (CSV)

6.1 Dataset enriquecido

Las tres tablas Silver se unen mediante `LEFT JOIN` para construir un dataset analítico de **96.148 filas** con las siguientes métricas calculadas:

- `revenue = quantity × price`
- `total_cost = quantity × cost`

- `gross_margin = revenue - total_cost`

6.2 Tabla: top_products (Q1)

Top 10 productos por ingreso total, con margen, unidades vendidas y precio medio.

Producto	Categoría	Ingresos	Margen
Cargador (v5)	Almacenamiento	$375.971	$158.507
SSD 1TB (v1)	Periféricos	$369.970	$160.241
Laptop Pro (v10)	Electrónica	$360.812	$342.767

6.3 Tabla: category_kpis (Q2 y Q5)

Categoría	Ingresos	Margen %	Ticket medio
Sin Categoría	$52.5M	12.86%	$2.759
Accesorios	$45.0M	7.62%	$2.726
Redes	$37.5M	6.21%	$2.753
Almacenamiento	$42.3M	5.25%	$2.715
Periféricos	$40.0M	5.03%	$2.787
Electrónica	$47.7M	0.36%	$2.789

Hallazgo: Electrónica genera el segundo mayor volumen de ingresos pero con un margen prácticamente nulo (0.36%), lo que sugiere una política de precios muy agresiva o costes de aprovisionamiento elevados.

6.4 Tabla: monthly_kpis (Q3)

El análisis mensual de 24 meses (enero 2023 – diciembre 2024) revela:

- **Ingresos medios mensuales:** ~$11.0M
- **Variabilidad mensual:** muy baja (±5%)
- **Conclusión:** Las ventas de TechZone son altamente estables sin estacionalidad significativa, lo que facilita la planificación de inventario y tesorería.

6.5 Tabla: country_kpis (Q4 y Q5)

País	Ingresos	Margen %	Clientes activos
Perú	$27.9M	5.01%	1.042
Argentina	$27.6M	7.04%	1.037
Colombia	$27.6M	5.74%	1.059
Chile	$25.8M	**7.80%**	955
España	$26.3M	6.11%	999

Hallazgo: Chile tiene el mejor margen bruto (7.80%) con menos clientes activos, lo que indica un perfil de cliente de mayor valor. Argentina y Chile son los mercados con mayor rentabilidad relativa.

---

7. Resultados globales

KPI	Valor
Ingresos totales (2023–2024)	**$264.905.782**
Margen bruto total	**$16.907.423**
Margen bruto %	**6.4%**
Ticket medio global	**$2.754**
Transacciones procesadas	**96.148**
Clientes activos	**10.000**
Países	**10**
Meses analizados	**24**

---

8. Conclusiones

1. **El pipeline ETL implementado** demuestra la viabilidad de la arquitectura Medallion con Spark puro en entornos locales, procesando más de 100.000 transacciones de forma eficiente.

2. **La separación Bronze/Silver/Gold** permite una trazabilidad completa desde el dato original hasta el KPI final, facilitando la auditoría y la corrección de errores.

3. **Electrónica es el talón de Aquiles** de TechZone con solo 0.36% de margen pese a ser la segunda categoría por ingresos. Se recomienda revisar la política de precios o renegociar con proveedores.

4. **Chile y Argentina** son los mercados más rentables con márgenes del 7.80% y 7.04% respectivamente, y deben ser prioritarios en la estrategia comercial.

5. **La ausencia de estacionalidad** en las ventas mensuales es una ventaja operativa que permite planificación uniforme a lo largo del año.

---

9. Estructura del repositorio

```
big-data-pipeline-medallion/
├── src/main/scala/com/example/
│   ├── generators/   ← Generación de datos sintéticos
│   ├── bronze/       ← 01_bronze.scala
│   ├── silver/       ← 02_silver.scala
│   └── gold/         ← 03_gold.scala
├── data/             ← Fuentes generadas (CSV, JSON, Parquet)
├── delta/            ← Capas del pipeline (Bronze, Silver, Gold)
├── dashboard/        ← CSVs para Power BI
└── build.sbt         ← Scala 2.13.13 + Spark 4.1.1
```